

Aqui está o build_index.py adaptado para o Genismo. **Instruções de uso:**

Instalação (uma vez só):

1. Salve o arquivo na **raiz** do repositório genismo (na mesma pasta do items.json e do index.html).
2. Para os 10 PDFs serem indexados, instale o pypdf. Abra o Prompt de Comando e rode: `pip install pypdf` (se não instalar, o script funciona mesmo assim — indexa os 360 .htm e apenas avisa que pulou os PDFs).

Uso no dia a dia (sempre que adicionar ou alterar artigos):

1. Adicione o artigo novo na pasta do repositório e inclua a entrada dele no items.json (com href, title, cat e catName — igual às entradas existentes).
2. Abra o Prompt de Comando na pasta do repositório (no Explorador de Arquivos, digite cmd na barra de endereço) e rode: `python build_index.py`
3. Ele mostra o progresso artigo por artigo e no final algo como "Concluído! 370 artigos indexados em search-index.json (3.9 MB)". Se algum arquivo do items.json não existir na pasta, ele avisa "PULADO" com o nome — útil para pegar erros de digitação nos links.
4. Commit + push pelo GitHub Desktop, espere o deploy e teste a busca.

Diferenças em relação ao fluxo do DUniverse: este script usa o items.json como fonte oficial (títulos e categorias vêm de lá, não dos arquivos), extrai texto de .htm além de PDFs, lida com a codificação antiga Windows-1252 dos arquivos de 2005, e trunca em 18.000 caracteres por artigo — o mesmo limite do índice atual, mantendo o tamanho do arquivo controlado.

Como o texto extraído agora vem mais limpo, recomendo rodar o script uma vez já de cara e commitar o novo search-index.json, mesmo sem artigos novos — os trechos exibidos nos resultados da busca vão melhorar. Qualquer coisa que aparecer estranha no relatório do script, me mostra que a gente ajusta!